Deploy

Pengaturan

Model AI

Google Gemini

Nama model

gemini-3.8-flash

Parameter model

Persona

Gaya bahasa

Santai Formal

Level kamu

Pemula

Pengetahuan (RAG)

Aktifkan RAG

Apa itu RAG dan kenapa bisa mengurangi halusinasi?

Selesai

Halo! Pertanyaan yang bagus banget buat yang baru mulai belajar LLM. Yuk, kita bedah pelan-pelan ya!

Berdasarkan catatan kita di **[panduan_llm_rag.md]** pada bagian *Halusinasi*, halusinasi adalah kondisi ketika LLM menghasilkan jawaban yang terdengar sangat meyakinkan, padahal isinya salah. Salah satu pemicunya adalah karena prompt tidak memberi konteks yang cukup jelas bagi model.

Nah, di sinilah **RAG** jadi pahlawannya!

Apa itu RAG?

Ketik pertanyaanmu...

Si Pintar | Final Project

localhost:8501

Chat

gemini-3.8-flash

Parameter model

Temperature
0.70

Top-p
0.95

Top-k (Gemini)
40
1 100

Max tokens
1024

Frequency penalty (Groq)
0.00

Presence penalty (Groq)
0.00

Persona

Deploy

Apa itu RAG dan kenapa bisa mengurangi halusinasi?

Selesai

Halo! Pertanyaan yang bagus banget buat yang baru mulai belajar LLM. Yuk, kita bedah pelan-pelan ya!

Berdasarkan catatan kita di **[panduan_llm_rag.md]** pada bagian *Halusinasi*, halusinasi adalah kondisi ketika LLM menghasilkan jawaban yang terdengar sangat meyakinkan, padahal isinya salah. Salah satu pemicunya adalah karena prompt tidak memberi konteks yang cukup jelas bagi model.

Nah, di sinilah **RAG** jadi pahlawannya!

Apa itu RAG?

Ketik pertanyaanmu...

28° 08:05

gemini-3.8-flash

Parameter model

Temperature
0.70

Top-p
0.95

Top-k (Gemini)
40

Max tokens
1024

Frequency penalty (Groq)
0.00

Presence penalty (Groq)
0.00

Persona

Deploy

Halusinasi

Halusinasi adalah kondisi saat LLM menghasilkan jawaban yang terdengar meyakinkan tetapi salah. Salah satu penyebabnya adalah prompt yang tidak memberi konteks cukup jelas. Cara mengurangi: beri konteks (RAG), minta model mengakui ketidaktahuan,...

Vector Database

Vector database menyimpan dan mencari data dalam bentuk vektor (deretan angka). Dokumen diubah menjadi vektor oleh embedding model, lalu pencarian dilakukan dengan kemiripan, misalnya cosine similarity, dan mengembalikan top-K vektor terdekat. Contoh: FAISS, Chroma, Qdrant (open s...

Parameter Model

- Temperature: mengontrol keacakan dan kreativitas. Temperature 0 bersifat deterministik.
- Max tokens: batas panjang output. Jika terlalu kecil, jawaban bisa terpotong.
- Top-p (nucleus sampling): memilih token dari probabilitas tertinggi hingga total mencapai nilai p.
- Top-k: m...

Ketik pertanyaanmu...